

Dipartimento di Fisica · Corso di Laurea in Fisica

Modelli data-driven per la viscosità dei liquidi sottoraffreddati

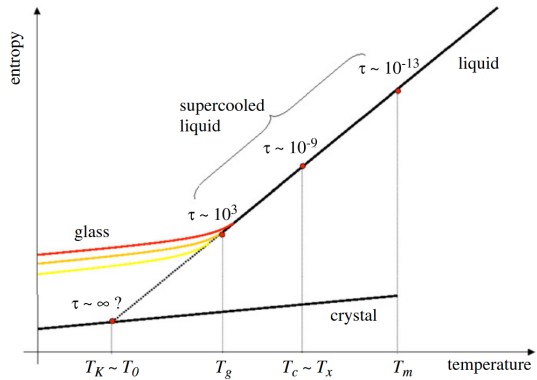
Laureando:
Denis-Cristian Pal

Relatore:
Prof. Daniele Coslovich

ANNO ACCADEMICO 2025–2026

Liquidi sottoraffreddati e transizione vetrosa

Un liquido si definisce **sottoraffreddato** quando viene portato al di sotto della sua temperatura di cristallizzazione T_m senza che avvenga la transizione di fase verso lo stato cristallino.



Entropia in funzione della temperatura (Cavagna, *Phys. Rep.*, 2009)

Andamento della viscosità ed equazione MYEGA

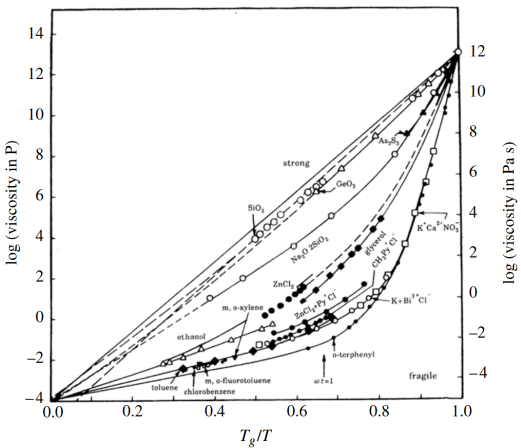


Grafico di Angell (Angell, *Science*, 1995)

Legge di Arrhenius

$$\eta(T) = \eta_\infty \exp\left(\frac{E_a}{k_B T}\right)$$

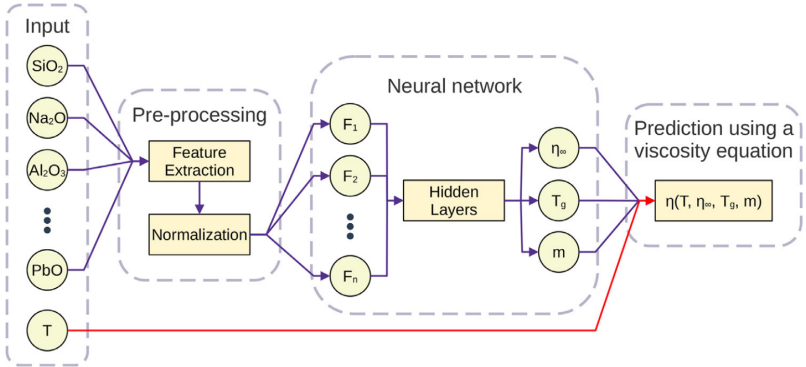
Modello MYEGA

$$\eta(T) = \eta_\infty \exp\left[\frac{K}{T}\exp\left(\frac{C}{T}\right)\right]$$

Riscrittura in funzione di T_g, m, η_∞

$$\log_{10}\eta(T) = \log_{10}\eta_\infty + (12 - \log_{10}\eta_\infty)\frac{T_g}{T}\times$$
$$\times \exp\left[\left(\frac{m}{12-\log_{10}\eta_\infty} - 1\right)\left(\frac{T_g}{T} - 1\right)\right]$$

Pipeline di lavoro



Flowchart della pipeline implementata nel modello ViscNet (Cassar, *Acta Mater.*, 2021)

Modello di regressione lineare: $y = w_0 + \sum_{i=1}^{M} w_i x_i = w_0 + \mathbf{w}^T \mathbf{x}$

Dataset ed estrazione delle *features*

Dati sperimentali e partizionamento

- Database di origine: **SciGlass** (liquidi formatori di vetro a base di ossidi)
- Dataset complessivo: **847 liquidi** (**17 584 misurazioni** di viscosità)
- *Training set*: **762 liquidi**
- *Unseen test set*: **85 liquidi**

Costruzione dei descrittori chimico-fisici

Dalle frazioni molari atomiche $\boldsymbol{C}$ e dalle proprietà chimiche elementari $\boldsymbol{S}$:

$$\boldsymbol{W} = \boldsymbol{C} \circ \boldsymbol{S}$$

$$\boldsymbol{A} = \lceil \boldsymbol{C} \rceil \circ \boldsymbol{S}$$

Applicando 5 funzioni di aggregazione statistica (*somma*, *media*, *deviazione standard*, *minimo*, *massimo*) si ottengono $\mathbf{M = 560}$ ***features***.

Modelli per la gestione della multicollinearità

Minimi Quadrati Ordinari (OLS)

$$\mathcal{L}_{\text{OLS}}(\mathbf{w}) = \frac{1}{2N}\|\mathbf{y} - X\mathbf{w}\|_2^2$$

Ridge Regression (L_2)

$$\mathcal{L}_{\text{Ridge}}(\mathbf{w}) = \frac{1}{2N}\|\mathbf{y} - X\mathbf{w}\|_2^2 + \frac{\alpha}{2}\|\mathbf{w}\|_2^2$$

Elastic Net ($L_1 + L_2$)

$$\begin{aligned}\mathcal{L}_{\text{EN}}(\mathbf{w}) &= \frac{1}{2N}\|\mathbf{y} - X\mathbf{w}\|_2^2 + \lambda_1\|\mathbf{w}\|_1 + \frac{\lambda_2}{2}\|\mathbf{w}\|_2^2 \\ &= \frac{1}{2N}\|\mathbf{y} - X\mathbf{w}\|_2^2 + \alpha\left(\beta\|\mathbf{w}\|_1 + \frac{1-\beta}{2}\|\mathbf{w}\|_2^2\right)\end{aligned}$$

$$\begin{cases}\alpha = \lambda_1 + \lambda_2 \\ \beta = \dfrac{\lambda_1}{\lambda_1 + \lambda_2} \in [0, 1]\end{cases}$$

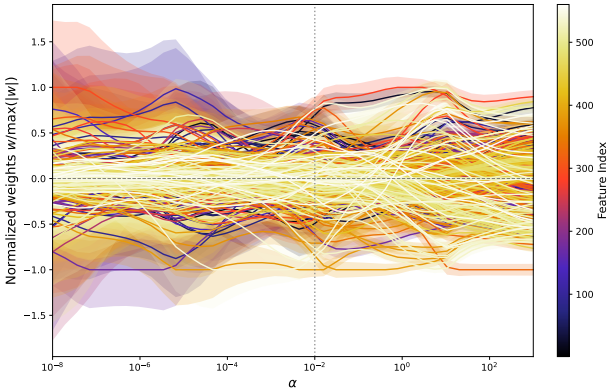
Filtraggio iterativo VIF

$$\text{VIF}_j = \frac{1}{1 - R_j^2} \qquad R^2 = 1 - \frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2}$$

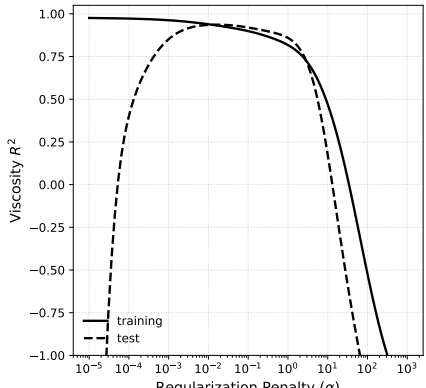
- **Procedura iterativa:** ad ogni ciclo si calcola il VIF_j regredendo ciascuna *feature* sulle restanti $M - 1$ e si elimina la variabile con valore massimo se $\text{VIF}_j > 10$ ($R_j^2 > 0.90$).
- **Riduzione dello spazio:** il filtraggio riduce i descrittori da 560 a 45 *features* ($\text{VIF}_j \leq 10$), sulle quali viene poi applicata la regressione OLS.
- **Confronto con ViscNet:** la stessa procedura è impiegato nella pipeline di pre-elaborazione di ViscNet prima dell'addestramento della rete neurale.

Scelta dei parametri: Ridge Regression

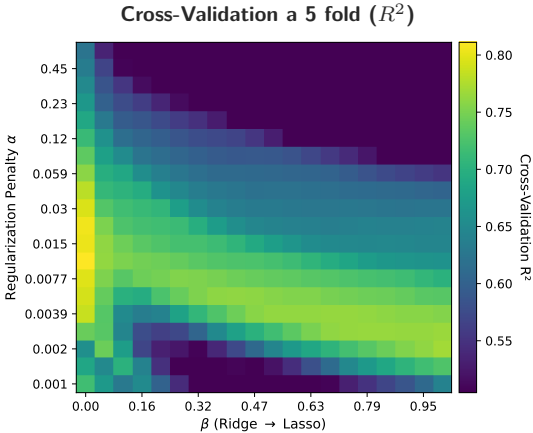
Tracce Ridge (T_g)



Performance su viscosità globale (R^2)



Scelta dei parametri: Elastic Net



- **Massimo assoluto:**

$$\beta = 0, \quad \alpha = 0.01$$

(corrispondente alla regressione Ridge).

- **Configurazione selezionata per indurre sparsità:**

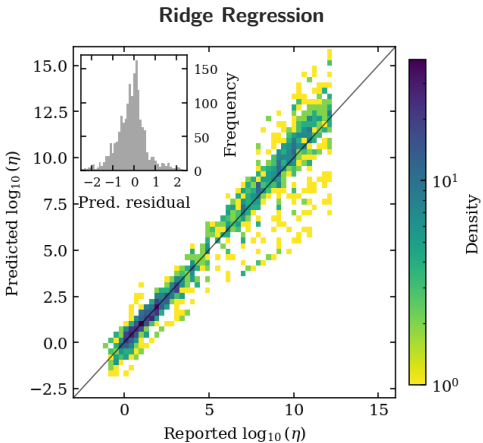
$$\alpha = 0.1, \quad \beta = 0.8$$

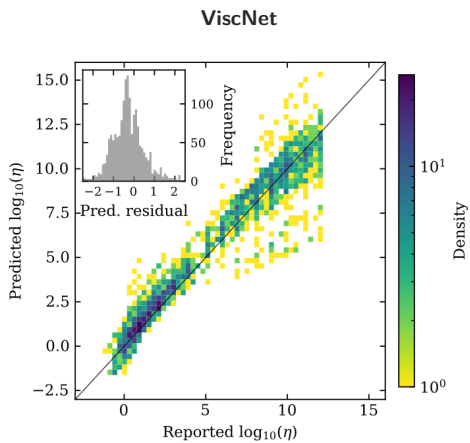
Valutazione delle performance predittive

Modello	Viscosità Globale R^2	Target: T_g R^2	Target: m R^2	Target: $\log_{10}\eta_\infty$ R^2
Ridge ($\alpha = 0.01$)	0.935	0.896	0.771	0.220
Elastic Net ($\alpha = 0.1$; $\beta = 0.8$)	0.806	0.778	0.712	0.162
VIF + OLS	0.776	0.819	0.761	0.200

Modello	R^2 (↑)	RMSE (↓)	MAE (↓)	MedAE (↓)
ViscNet	0.926	1.100	0.780	0.530
Ridge Regression	**0.935**	**1.031**	**0.657**	**0.392**

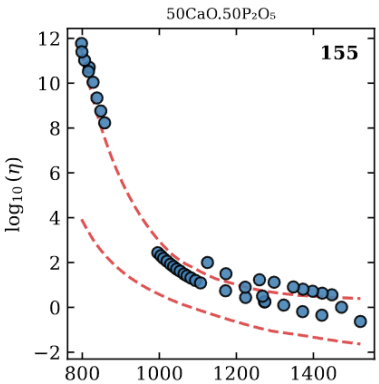
Qualità dell'interpolazione



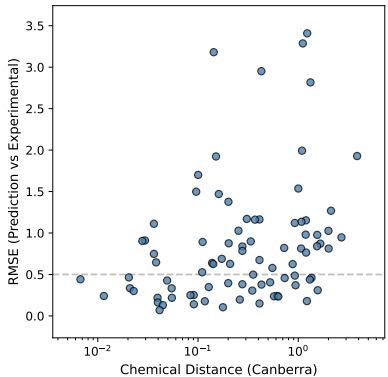


Incertezza dei dati e distanza chimica

Sovrapposizione sperimentale (ID 155)

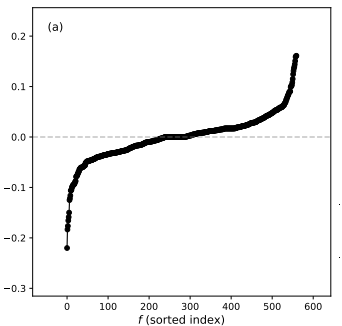


Errore in funzione della composizione chimica

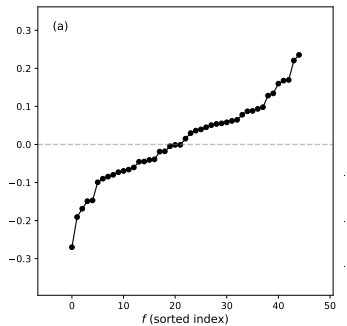


Distribuzione dei pesi per T_g

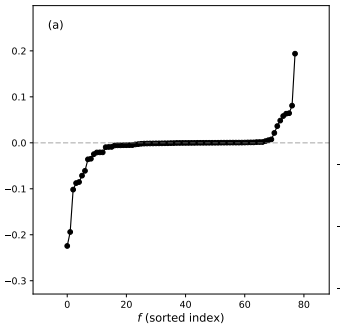
Ridge Regression



VIF + OLS



Elastic Net



Analisi dei pesi principali per T_g (Elastic Net)

Rank	Feature	Peso
1	W_Sum_GSbandgap	-0.224
2	W_Sum_NsUnfilled	-0.194
3	W_Sum_NsValence	0.194
4	W_Std_density	-0.102
5	W_Max_GSbandgap	-0.088
6	A_Std_zeff	-0.085
7	A_Max_vdw_radius_uff	0.081
8	A_Max_zeff	-0.071
9	A_Max_FusionEnthalpy	0.064
10	A_Max_NpUnfilled	0.063

Interpretabilità dei modelli lineari

- **Ridge:** conserva l'intero spazio delle 560 *features* raggiungendo le prestazioni più elevate ($R^2 = 0.935$), ma produce una distribuzione continua dei pesi priva di poche variabili dominanti ("scatola nera lineare").

- **Elastic Net:** seleziona descrittori fisicamente coerenti (*bandgap*, raggio di Van der Waals, entalpia di fusione), ma comporta un calo di accuratezza ($R^2 = 0.806$) e mantiene compensazioni matematiche tra variabili correlate.

- **VIF + OLS:** la riduzione delle *features* collineari stabilizza la stima OLS, ma la distribuzione dei pesi rimane continua senza indicare variabili più importanti delle altre.

Conclusioni

- **Accuratezza:** sfruttando l'intero insieme di 560 *features* regolarizzate tramite norma L_2, la regressione lineare Ridge supera la rete neurale ViscNet ($R^2 = 0.935$ vs 0.926, RMSE $= 1.031$, MedAE $= 0.392$) ed evita il *bias* di sovrastima alle basse viscosità.

- **Perdita di interpretabilità nei sistemi complessi:** l'impossibilità di isolare un set ristretto di descrittori senza degradare le performance sembra essere indipendente dal modello adottato e conseguenza dalla natura cooperativa della transizione vetrosa.

- **Vantaggi della regressione lineare:** a parità di accuratezza con le reti neurali, il modello lineare offre un addestramento immediato, indipendente dal numero di features, e definisce una mappa globale e costante delle correlazioni termodinamiche.

Backup: Regressione su Componenti Principali (PCR e SPCR)

Diagonalizzazione della matrice di correlazione empirica $C = \frac{1}{N_s} X^T X$:

$$C = U \Lambda U^T \qquad \Longrightarrow \qquad \tilde{X}^{(f)} = \frac{(XU)^{(f)}}{\sqrt{\lambda^{(f)}}}$$

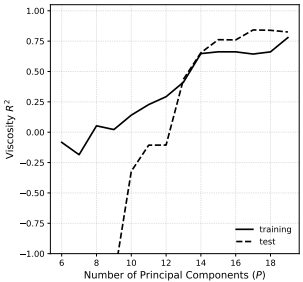
Regressione lineare su un sottospazio di $P \ll M$ componenti ortogonali:

$$\hat{y} = \sum_{f=1}^{P} R[\tilde{X}^{(f)}, y] \tilde{X}^{(f)}$$

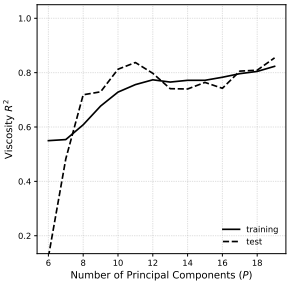
- **PCR classica (non supervisionata):** trattiene le prime P componenti ordinate per varianza strutturale spiegata ($\lambda^{(f)}$ decrescente).
- **Supervised PCR (SPCR):** ordina e seleziona le P componenti in base al valore assoluto della correlazione di Pearson con ciascun target $|R[\tilde{X}^{(f)}, y]|$.

Backup: Scelta di P e performance (PCR vs SPCR)

PCR ($P = 14$)



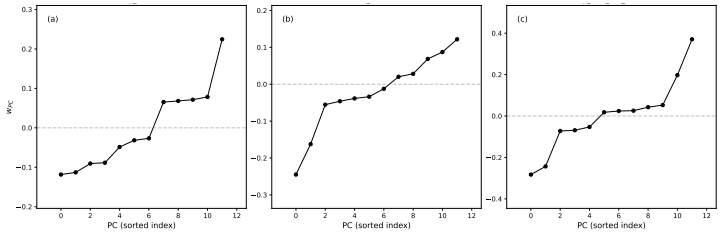
Supervised PCR ($P = 12$)



Modello	Viscosità Globale R^2	Viscosità Globale RMSE	Target: T_g R^2	Target: m R^2	Target: $\log_{10}\eta_\infty$ R^2
Ridge ($\alpha = 0.01$)	0.935	1.031	0.896	0.771	0.220
SPCR ($P = 12$)	0.798	1.825	0.773	0.731	0.283
PCR ($P = 14$)	0.655	2.383	0.713	0.731	0.134

Backup: Proiezione dei pesi nella Supervised PCR ($P = 12$)

Pesi nello spazio delle Componenti Principali (T_g, m, $\log_{10}\eta_\infty$)



Proiezione a ritroso dei pesi nello spazio delle 560 *features* iniziali

